

HSK RAG 공급망 시나리오·비관련 질의 테스트 (최종 — CRAG 적용)

작성일 2026-06-12 · 시스템: RRF 하이브리드 검색 + LLM 품목 추출 + **CRAG 1회 보정**(검색 결과를 LLM 평가기가 fit/ambiguous/unrelated 로 판정 — ambiguous 는 대체 키워드 재검색·병합, unrelated 는 즉시 거부) + qwen3:14b agent.

확인 요청 사항 회신 (최종)

확인 요청	회신
1. HS Code 키워드가 없는 공급망 시나리오 문장에서 추천 가능한지	가능 — 6/6 전건 유효 추천. 품목 추출이 "관세 부과 영향 분석해줘"에서 품목만 분리하고, 'WTI' 같은 시세 약어는 동의어 사전·CRAG 보정('원유' 재검색)이 처리. 기업/영향 분석 자체는 graph-analysis API 영역이며 본 API 는 입력 시드(HS 코드)를 공급.
2. 추천 신뢰도(Score) 제공 가능한지	제공 중. 모든 후보에 RRF score (3시그널 만점 ≈0.0492 / 2시그널 ≈0.0328 / 1시그널 ≈0.0164). 0.033 미만은 low_confidence 로 자동 로깅. 단 점수 하드컷은 권장하지 않음 — 아래 4번 참조.
3. 비관련 질의를 무리하게 추천하지 않는지	5/5 명시 거부. CRAG 평가기의 의도 판정(unrelated → 즉시 "확실하지 않음 (품목 조회와 무관)"). 저신뢰 score 플래그(전건 0.0164)와 2중 안전망.
4. False Positive 발생 여부	0건. 1차 테스트의 유일한 FP('김치볶음밥 레시피' → 김치 인용)는 CRAG 의도 판정 도입으로 해소 — 품목명이 실재해도 질의 의도가 무역 조회가 아니면 거부.

1. 공급망 시나리오 (6문항)

질의	top3 (score)	top1	agent 답변	판정
유럽연합(EU)이 한국산 철강 제품에 추가 관세를 부과했을 때 영향을 분석해줘.	7326200000 0.0477 철강선으로 만든 제품 6809900000 0.0318 그 밖의 제품 1905901000 0.0308 베이커리 제품	0.0477	7326200000 — 철강선으로 만든 제품 6809900000 — 그 밖의 제품 1905901000 — 베이커리 제품 6815200	○ 유효 추천
철강 제품 관련 기업 알려줘.	7326200000 0.0479 철강선으로 만든 제품 6809900000 0.0312 그 밖의 제품 6815200000 0.0311 이탄(泥炭)제품	0.0479	7326200000 — 철강선으로 만든 제품 6809900000 — 그 밖의 제품 6815200000 — 이탄(급炭)제품 190590	○ 유효 추천
철강 제품 수입이 중단되었을 때 영향을 받는 기업은?	7326200000 0.0477 철강선으로 만든 제품 6809900000 0.0318 그 밖의 제품 1905901000 0.0308 베이커리 제품	0.0477	7326200000 — 철강선으로 만든 제품 6809900000 — 그 밖의 제품 1905901000 — 베이커리 제품 6815200	○ 유효 추천
철강 제품 수입이 늘어나면 발생하는 파급효과는?	7326200000 0.0477 철강선으로 만든 제품 6809900000 0.0318 그 밖의 제품 1905901000 0.0308 베이커리 제품	0.0477	7326200000 — 철강선으로 만든 제품 6809900000 — 그 밖의 제품 1905901000 — 베이커리 제품 6815200	○ 유효 추천
WTI 가격이 20% 상승하면 어떤 기업이 영향을 받아?	2709002000 0.0487 역청유(瀝靑油) 2009710000 0.0308 브릭스(Brix) 값이 20 이하인 것 2009410000 0.0308 브릭스(Brix) 값이 20 이하인 것	0.0487	2709001010 — 섭씨 15도에서 비중이 0.796 초과 0.841 이하인 것 2709002000 — 역청유(瀝靑油) 2709001	○ 유효 추천 (CRAG 보정 경유)
중국의 희토류 수출 제한 시 영향을 받는 기업은?	2805305000 0.0492 스칸듐 2805304000 0.0479 이트륨 2846901000 0.0467 산화이트륨	0.0492	2805305000 — 스칸듐 2805304000 — 이트륨 2846901000 — 산화이트륨 2846909000 — 기타 280	○ 유효 추천

철강 3종 의도(영향/기업/수입중단/파급효과)와 무관하게 '철강 제품' 추출 → 73류 0.0477~0.0479. 희토류 → 스칸듐·이트륨 만점 0.0492. WTI → 동의어 확장으로 역청유 0.0487 + CRAG 가 '원유'로 재검색·보정해 2709 원유 코드를 1~3위로 인용.

2. 비관련 일반 질의 (5문항)

--	--	--	--	--

질의	top3 (score)	top1	agent 답변	판정
김치볶음밥 레시피 알려줘.	0710300000 0.0164 시금치류 2005991000 0.0164 김치 1904901010 0.0161 찌거나 삶은 쌀	0.0164	거부	○ 명시 거부
오늘 서울 날씨 어때?	2818301000 0.0164 알루미나겔 8902001000 0.0164 어선 0105991000 0.0161 오리	0.0164	거부	○ 명시 거부
아이폰과 갤럭시 중 뭐가 좋아?	3304201000 0.0164 아이새도 7015901000 0.0164 선글라스용 2105001000 0.0161 아이스크림	0.0164	거부	○ 명시 거부
강아지 산책은 하루 몇 번 해야 해?	5102200000 0.0164 동물의 거친 털 9202902000 0.0164 하프 0508001000 0.0161 산호	0.0164	거부	○ 명시 거부
엑셀 피벗테이블 만드는 방법 알려줘.	1404905000 0.0164 비나 브러시를 만드 는 데 주로 사용되는 5905000000 0.0164 방직용 섬유로 만든 벽 피복재 8443120000 0.0164 오프셋(offset) 인쇄기 계[사무실용	0.0164	거부	○ 명시 거부

3. 검증 과정에서 확정된 설계 결정 2건

점수 하드컷(0.033) 폐기. 직전 리포트에서 권고했던 score 컷을 120문항 데이터로 재검증한 결과, 정답 40건(rank 1 포함: 열연강판·LNG 등)이 0.0164~0.0328 구간에 존재해 오차단됨을 확인. RRF 점수는 "시그널 합의 수"이지 정오 확률이 아니므로 — 점수는 모니터링·저신뢰 큐 분류용으로만 쓰고, 정오 판단은 CRAG LLM 평가기가 담당하는 구조로 확정.

의도 가드를 답변 프롬프트가 아닌 평가기로 분리. 의도 거부 지시를 답변 프롬프트에 넣자 "나열하라"와 "거부하라"가 충돌해 시나리오 6건 전부가 과잉 거부되는 회귀가 발생(중간 테스트). 판단(평가기)·생성(답변기)을 분리해 해소 — 각 프롬프트가 단일 책임을 가진다.

4. CRAG 동작 구조

검색 → 평가기(fit/ambiguous/unrelated) → fit: 답변 | ambiguous: 대체 키워드 재검색·병합 (+해석 주석과 함께 답변) | unrelated: 즉시 거부(답변 LLM 생략)

- fail-safe: 평가기 실패/타임아웃 → fit 폴백 (기존 동작과 동일, 커서 나빠질 수 없음). RAG_CRAG 로 토글.
- 보정 검색은 search_log 에 [crag] 키워드' 로 기록 — 야간 self-play 동의어 학습의 입력이 되어, 런타임 보정이 반복되는 갭은 사전에 영구 등록되는 선순환.
- 비용: 문항당 평가기 LLM 1회 추가(CPU ~10초, GPU ~1초). unrelated 는 답변 생성을 생략해 오히려 단축.

5. 엔드포인트 사용 가이드

	/api/hsk/search	/api/hsk/agent
용도	시스템 연동 — 후보+score, 빠름(키워드 ~0.2초, 문장형 ~3.5초*)	사용자 화면 — CRAG 보정 + LLM 답변/거부, citations 동봉(*CPU 수십 초, GPU 수 초)
신뢰도 처리	score 는 참고 지표(하드컷 비권장), low_confidence 자동 로깅	CRAG 의도 판정 + "확실하지 않음" 거부

* CPU(dev) 기준. 공급망 영향·기업 분석은 본 API 의 HS 코드 시드 → graph-analysis(s_ra604 기업 매핑, 전·후방 전파)와 조합.